

Titre

Pipeline ETL automatisé des ventes Amazon vers Snowflake (Airflow + Snowflake)

Résumé du projet

Projet conçu pour centraliser les données de ventes (site, magasins physiques, réseaux sociaux) afin d'améliorer les décisions commerciales.

Le pipeline extrait les données sources (Kaggle Amazon Sales), exécute le nettoyage et l'enrichissement via les scripts Python `extract.py` et `transform.py`, puis produit le fichier `amazon_clean.csv`. Apache Airflow orchestre le chargement vers la table `PRODUCTS` de Snowflake à l'aide du DAG `etl_to_snowflake`. En local sur Windows lancer `python extract.py` puis `python transform.py` pour générer `amazon_clean.csv`. Sur WSL2 placer le DAG dans `~/airflow/dags`, vérifier la connexion Airflow `snowflake_conn`, puis démarrer `scheduler` et `webserver`. Le DAG est programmé chaque semaine le lundi à 03:00 (CRON `0 3 * * 1`).

Résultat

La table `PRODUCTS` dans Snowflake contient les ventes nettoyées et agrégées, prêtes pour les analyses BI.

Valeur business : identification des produits les plus vendus, repérage des pics de demande et détection de tendances pour optimiser offres et stocks. Automatisation hebdomadaire assure des données à jour.